

Klasifikace textu do rozsáhlé taxonomie IPTC Media Topics je náročná, pokud spoléháme pouze na husté reprezentace dokumentů (embeddings), kterým často chybí explicitní faktický kontext pro vzácné pojmenované entity. Tato práce zkoumá vylepšení vícejazyčného klasifikátoru zpráv pomocí integrace znalostí o reálných entitách. Navrhujeme modulární architekturu s pozdní fúzí (late-fusion), která kombinuje standardní textové reprezentace se strukturovanými reprezentacemi entit získanými z platforem Wikidata a Wikipedia. Systematicky jsme vyhodnotili různé zdroje reprezentací, techniky fúze příznaků a strategie sdružování (pooling). Výsledky potvrzují, že modely využívající informace o entitách konzistentně překonávají základní textový model. Nejlepší konfigurace, využívající mechanismus pozornosti (attention) k agregaci vícejazyčných vektorů entit, dosáhla zlepšení o 1,7 % v metrice Micro F_1 a o 2,4 % v metrice Macro F_1 . Toto zlepšení bylo obzvláště výrazné ve specifických doménách, jako je sport, což dokazuje, že strukturované znalosti entit efektivně řeší problém řídkosti dat a zvyšují praktickou úspěšnost klasifikace.